Source S1

narrative, 157 characters; Thai marks no sentence ends

เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร ตกใจมาก จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234

1 Split lines, then sentences

SaT segmenter; PyThaiNLP crfcut as fallback

เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง

แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร

ตกใจมาก

7 chars

จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234

2 Merge pieces under 25 characters into the next

เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง

แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร

ตกใจมาก จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234

3 Cut into contiguous units

separators kept; table rows split; at most 2,000 characters

`U001 [0,73)`

`U002 [73,107)`

`U003 [107,157)`

Invariant: every unit's text equals $source[start{:}end]$, and joining the units in order gives back the source exactly.

4 Give each unit a content-addressed ID

```
h = SHA-256("evidence_units_v3" \0 source_text)[:16]
  = 80a1d348f2908e99

S1:U001-80a1d348f2908e99, S1:U002-80a1d348f2908e99, …
```

Changing one character of S1 changes h, so an identifier issued for the old text can never resolve against the new one (`stale_id`).

5 Show the model short aliases; keep the map

The Reader sees `U001`–`U003` with their text only: no offsets, no hashes. The request records `S1` ↦ `80a1d348f2908e99` *before* the Reader call and uses it to expand a selected alias back to its canonical ID.