Source S_1

narrative, $|S_1| = 157$; Thai marks no sentence ends

เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร ตกใจมาก จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234

1 Split lines, then sentences

SaT segmenter; PyThaiNLP crfcut as fallback

เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง

แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร

ตกใจมาก

7 chars

จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234

2 Merge pieces under $\delta = 25$ characters into the next

เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง

แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร

ตกใจมาก จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234

3 Cut into contiguous units $U(S)$

separators kept; table rows split; at most $L = 2{,}000$ characters

`U001 [0,73)` | `U002 [73,107)` | `U003 [107,157)`

Invariant: every unit's text equals $source[start{:}end]$, and joining the units in order gives back the source exactly.

4 Give each unit a content-addressed ID $id(u)$

h_{S1} = `SHA-256("evidence_units_v3" \0 source_text)[:16]`
= `80a1d348f2908e99`

`S1:U001-80a1d348f2908e99, S1:U002-80a1d348f2908e99, …`

Changing one character of S1 changes h, so an identifier issued for the old text can never resolve against the new one (`stale_id`).

5 Show M_R short aliases $\alpha(u)$; keep the map

The reader model M_R sees aliases $\alpha(u) =$ `U001`–`U003` with their text only: no offsets, no hashes. The request records S1 $\mapsto h_{S1} =$ `80a1d348f2908e99` *before* calling M_R and uses it to expand a selected alias back to its canonical ID.