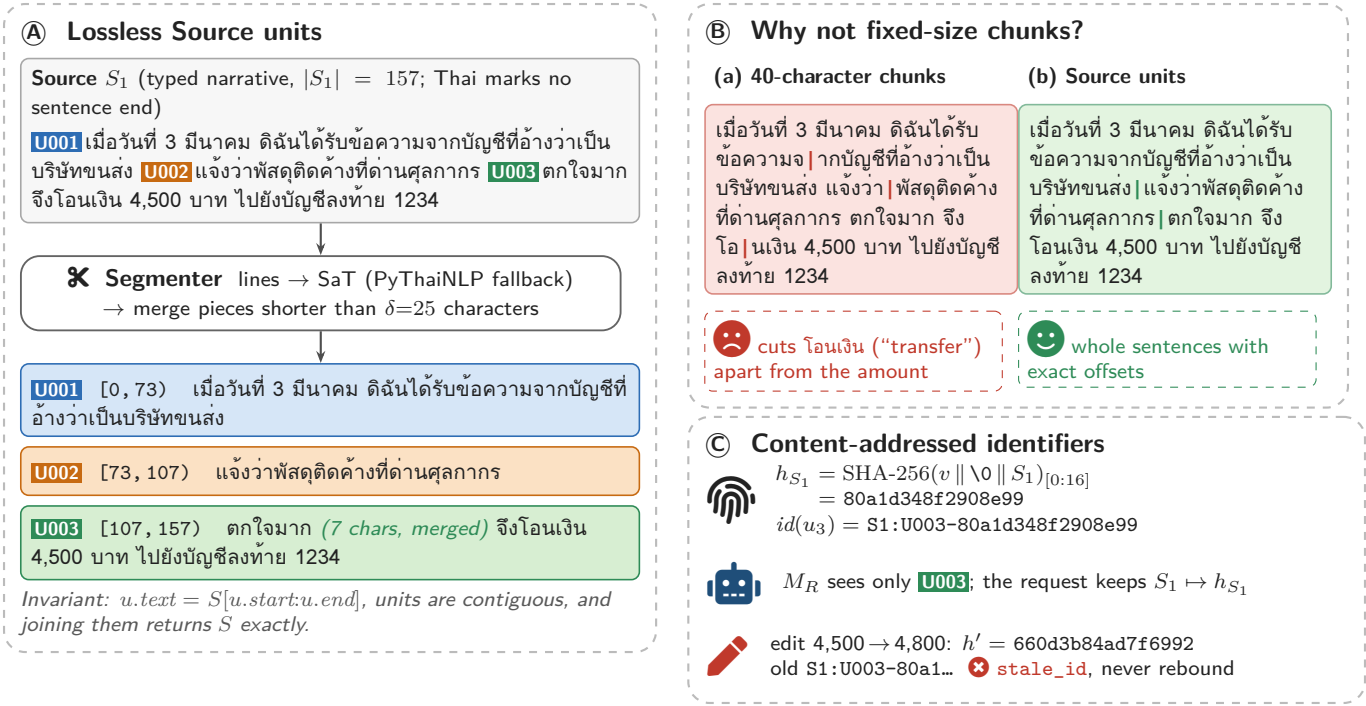
Ⓐ Lossless Source units
Source S_1 (typed narrative, $|S_1| = 157$; Thai marks no sentence end)
U001 เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง U002 แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร U003 ตกใจมาก จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234
Segmenter lines → SaT (PyThaiNLP fallback)
→ merge pieces shorter than δ=25 characters
U001 [0, 73) เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง
U002 [73, 107) แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร
U003 [107, 157) ตกใจมาก (7 chars, merged) จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234
Invariant: $u.text = S[u.start{:}u.end]$, units are contiguous, and joining them returns S exactly.
Ⓑ Why not fixed-size chunks?
(a) 40-character chunks
เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจ|ากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง แจ้งว่า|พัสดุติดค้างที่ด่านศุลกากร ตกใจมาก จึงโอ|นเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234
cuts โอนเงิน ("transfer") apart from the amount
(b) Source units
เมื่อวันที่ 3 มีนาคม ดิฉันได้รับข้อความจากบัญชีที่อ้างว่าเป็นบริษัทขนส่ง|แจ้งว่าพัสดุติดค้างที่ด่านศุลกากร|ตกใจมาก จึงโอนเงิน 4,500 บาท ไปยังบัญชีลงท้าย 1234
whole sentences with exact offsets
Ⓒ Content-addressed identifiers
$h_{S_1} = \mathrm{SHA\text{-}256}(v \,\|\, \backslash 0 \,\|\, S_1)_{[0:16]}$
$= 80a1d348f2908e99$
$id(u_3) =$ S1:U003-80a1d348f2908e99
M_R sees only U003; the request keeps $S_1 \mapsto h_{S_1}$
edit 4,500 → 4,800: $h' = 660d3b84ad7f6992$
old S1:U003-80a1… stale_id, never rebound