

สรุปงานประเมินผลและปรับปรุง pipeline

CyberCase Intelligence Framework · branch `eval/published-baselines` · 30 commits

ขอบเขต: สร้างชุดทดสอบเทียบกับงานวิจัยที่ตีพิมพ์ · วัดผล pipeline · แก้ข้อบกพร่องที่พบระหว่างการวัด

ผลสรุปสามข้อ

- วัด pipeline ที่ให้บริการจริงได้เป็นครั้งแรก — บนสำนวนคดีไทย **F1 0.746** (gpt-5.6-luna) และ **0.576** เมื่อเปลี่ยนเป็นโมเดลเปิดขนาด 9B
- ผลของแต่ละองค์ประกอบกลับด้านตามภาระงาน การค้นคืนและ re-ranker ทำให้แยลงบนชุดทดสอบภายนอก แต่ทำให้ดีขึ้นชัดเจนบนโจทย์จริง — วัดได้ทั้งสองทิศทางในการทดลองเดียวกัน
- พบและแก้ข้อบกพร่องใน production **6 จุด** ทั้งหมดเป็นชนิดที่ไม่ทำให้ระบบพัง จึงไม่มีใครเห็นจนกระทั่งรัน pipeline จริง

1. สิ่งที่สร้างขึ้น

ส่วนประกอบ	หน้าที่
<code>fetch_datasets.py</code>	ดึงชุดทดสอบของ TechniqueRAG จาก HuggingFace (TRAM 725 · Expert 157 · Procedures 1,767)
<code>metrics.py</code>	ตัวชี้วัดตามโปรโตคอลต้นทาง · unit test 18 รายการ
<code>attack_version_map.py</code>	แปลงรหัส ATT&CK v14 → v19 จากความสัมพันธ์ <code>revoked-by</code> ในไฟล์ STIX
<code>run_benchmark.py</code>	ตัวรัน 5 arm · รองรับ resume · เลือกโมเดล · เลือกชุดข้อมูล
<code>clean_corpus.py</code>	สร้างดัชนีที่ล้างข้อความประกอบออก ลงคอลเลกชันแยก
<code>build_reranker_trainset.py</code>	สร้างชุดฝึก re-ranker พร้อมตัดข้อมูลที่ทับซ้อนกับชุดทดสอบ
ชุดทดสอบสำนวนคดีไทย	ต่อ <code>real_cti</code> 100 เรื่อง (ไทย + อังกฤษคู่ขนาน) เข้ากับ harness เดียวกัน

การพิสูจน์ความถูกต้องของการวัด

- ตัวชี้วัดตรงกับต้นทาง — เทียบกับ `evaluate.py` ของ TechniqueRAG บนข้อมูลสุ่ม 400 ชุด ทั้งสองโหมด P/R/F1 ตรงกัน คลาดเคลื่อนไม่เกิน $1e-12$
- ปรับปรุง ATT&CK — 196 คู่จาก `revoked-by` หลังแปลงแล้วป้ายเฉลยทุกรายการค้นคืนได้ครบ 100%
- ตัดข้อมูลทับซ้อน — ชุดฝึกที่เสนอ 18,383 รายการทับซ้อนกับชุดทดสอบ 1,656 รายการ (9%) ตัดออกแล้วเหลือ 15,915 เทียบข้อความตรง ๆ ตรวจไม่พบเลย เพราะชุดทดสอบตัดชื่อผู้กระทำออกจากต้นประโยค ต้องเทียบแบบบรรจุอยู่ภายในบนข้อความที่ทำให้เป็นมาตรฐานแล้ว

2. ตารางผลลัพธ์

2.1 สำนวนคดีไทย — โจทย์จริงของระบบ (n=100)

arm	P	R	F1	P@1	ID/เรื่อง
agent · gpt-5.6-luna	0.689	0.813	0.746	0.730	4.8
agent · qwen3.5-9b	0.562	0.591	0.576	0.640	4.2
retrieval + re-ranker	0.120	0.507	0.195	0.530	20.0
retrieval ไม่ใช้ re-ranker	0.120	0.507	0.195	0.430	20.0

ชุดข้อมูล: สำนวนคดีเขียนด้วยมือจากคำเตือน CISA และแผนจำลอง CTID · ความยาวมาตรฐาน 688 ตัวอักษร · เฉลย 3 เทคนิคต่อเรื่อง · ตอบเป็นภาษาไทย 100/100 ทั้งสองโมเดล · ไม่มีข้อผิดพลาดระหว่างรัน

การเปรียบเทียบโมเดลบน pipeline เดียวกัน — เหตุการณ์ชุดเดียวกัน 100 เรื่อง prompt เดียวกัน ต่างกันเพียงโมเดล
ช่องว่าง **0.170 F1** ไม่ใช่ระดับที่เรียกได้ว่าเทียบเท่า โมเดลเปิด 9B ทำได้ **77%** ของสมรรถนะโมเดลเชิงพาณิชย์
ตำแหน่งของช่องว่างบอกอะไรมากกว่าขนาด — **recall** ต่าง **0.222** (0.813 เทียบ 0.591) ขณะที่ precision ต่างไม่ถึงครึ่งหนึ่งของ
นั้น ทั้งสองได้ context ชุดเดียวกันปะ โมเดลเล็กจึงไม่ได้ถูกจำกัดด้วยการค้นคืน แต่**สกัดเทคนิคที่ถูกออกจาก context** เดียวกัน
ได้น้อยกว่า คอขวดอยู่ที่การอ่าน context ยาว มีใช้ที่ตัวค้นคืน

ข้อความที่เขียนได้: “บน pipeline และชุดข้อมูลเดียวกัน โมเดลเปิดขนาด 9B ทำได้ F1 0.576 เทียบกับ 0.746 ของโมเดลเชิงพาณิชย์ คิดเป็น 77% ของสมรรถนะ โดยมีค่าใช้จ่ายด้าน output ต่ำกว่า 8 เท่า และติดตั้งภายในองค์กรได้ ซึ่งเป็นข้อกำหนดของงานที่ประมวลผลส่วนบุคคล” — เป็นข้อโต้แย้งเรื่องการแลกเปลี่ยน มีใช้เรื่องคุณภาพที่เท่ากัน

2.2 TRAM — ชุดทดสอบภายนอก (n=713)

arm	P	R	F1	P@1	preds
โมเดล qwen/qwen3.5-9b					
agent — pipeline จริง	0.328	0.568	0.416	0.396	4.1
rag-en (ablation)	0.495	0.675	0.571	0.582	3.7
llm-only	0.260	0.359	0.302	0.288	—
โมเดล gpt-5.6-luna					
rag-en (ablation)	0.589	0.665	0.625	0.621	1.3
llm-only	0.653	0.738	0.693	0.687	—
การค้นคืนอย่างเดียว ไม่มี LLM					
retrieval k=20 กรองเฉพาะ technique	0.070	0.805	0.129	0.373	19.9
retrieval k=20 ไม่ใช่ re-ranker	0.070	0.805	0.129	0.396	19.9
retrieval k=5	0.183	0.609	0.282	0.394	4.9

2.3 เทียบกับตัวเลขที่ดีพิมพ์ — TRAM ระดับ technique

ระบบ	ประเภท	P	R	F1
NCE	retriever	0.903	0.789	0.842
TechniqueRAG	fine-tuned	0.760	0.721	0.740
BM25	retriever	0.679	0.647	0.663
IntelEx	RAG	0.607	0.707	0.653
DeepSeek v3 (RAG)	RAG	0.546	0.774	0.640
ของเรา — rag-en · luna	RAG	0.589	0.665	0.625
GPT-4 (RAG)	RAG	0.555	0.706	0.622
ของเรา — rag-en · qwen3.5-9b	RAG	0.495	0.675	0.571
 Minstral 8B (RAG) — คู่เทียบที่คุ้มตัวแปร	RAG	0.519	0.576	0.546
DeepSeek v3	zero-shot	0.437	0.657	0.525
GPT-4o	zero-shot	0.383	0.500	0.434
Minstral 8B	zero-shot	0.077	0.317	0.124

ข้อจำกัดที่ต้องระบุ: TechniqueRAG ผ่านการ fine-tune บน train split จึงไม่ใช่คู่เทียบโดยตรงของ arm ไດ คู่เทียบที่คุมตัวแปรได้มากที่สุดคือ Ministral 8B (RAG) — generator ขนาดใกล้เคียง ไม่ fine-tune ทั้งคู่ ช่องว่าง 0.169 เทียบกับตัวเลขพาดหัว สอดคล้องกับ ablation ในงานเดียวกันซึ่งระบุว่าการ fine-tune อย่างเดียวให้ผลต่าง +0.194

2.4 ผลของแต่ละองค์ประกอบ แยกตามภาระงาน

องค์ประกอบ	TRAM (ประโยค 95 ตัวอักษร)	สำนวนคดีไทย (688 ตัวอักษร)
re-ranker	-0.023 P@1	+0.100 P@1
pipeline เติม เทียบกับ ablation	-0.155 F1	+0.381 F1
การค้นคืน (โมเดลที่ไม่จำคำตอบ)	+0.269 F1 —	
การค้นคืน (โมเดลที่นำจะจำคำตอบ)	-0.068 F1 —	

ทุกองค์ประกอบให้ผลตรงข้ามกันเมื่อเปลี่ยนภาระงาน ระบบนี้ถูกออกแบบมาสำหรับสำนวนคดีหลายขั้นตอน บนชุดทดสอบที่เป็นประโยคเดียว องค์ประกอบเดียวกันกลับเป็นภาระ — เช่น agent ระบุ 4.1 เทคนิคต่อเฉลย 1.2 บน TRAM แต่ระบุ 4.2 ต่อเฉลย 3.0 บนสำนวนคดีไทย ซึ่งพอดีกัน

2.5 การทดลองปรับปรุงการค้นคืน — ผลบทั้งหมด

การทดลอง	สมมติฐาน	ผลต่อ P@1
กรองเหลือเฉพาะ technique	ผลลัพธ์ประเภท Group/Software แยงตำแหน่งต้นตาราง	0.384 → 0.373
ล้างข้อความประกอบ 18.5%	citation และลิงก์บังคับเนื้อหาจริง	0.373 → 0.363
แก้การรวมคะแนนข้าม collection	candidate ที่ถูกต้องถูกเบียดออก	0.384 → 0.388
ลด top-K เป็น 5	pool ใหญ่เปิดช่องให้จัดอันดับผิด	0.373 → 0.394
ปิดตัวจัดอันดับใหม่	cross-encoder อาจไม่ช่วย	0.373 → 0.396

ไม่มีการทดลองโดยก P@1 บน TRAM เกินระดับสัญญาณรบกวน แต่การแก้การรวมคะแนนยังคงมีคุณค่าในตัวเอง — candidate ที่เป็น technique เพิ่มจาก 7.9 เป็น 12.1 ต่อคำถาม และตัวอย่างที่ไม่ได้ผลลัพธ์เลยลดจาก 6 เหลือ 1 และข้อสรุปว่า "ไม่ควรใช้ re-ranker" ถูกกลับด้านในภายหลังเมื่อวัดบนสำนวนคดีไทย

3. ข้อบกพร่องที่พบและแก้

ทั้งหกจุดมีลักษณะร่วมกัน คือ **ไม่ทำให้ระบบพัง** จึงไม่ปรากฏจนกระทั่งมีการวัดผล pipeline จริง สิ่งจุดแรกเป็นผลจากการเปลี่ยนสถาปัตยกรรมแล้วเก็บของเดิมไว้โดยปิดทับแทนการรื้อ

จุด	อาการ	การแก้ไข
router	จำแนกประเภทคำถามทุกครั้งแล้วทิ้งผลลัพธ์ — เส้นเชื่อมถูกกำหนดตายตัวเป็นเส้นทางเดียว ทำให้เสีย LLM call ฟรีทุกคำถาม	ถอดออกจาก graph ทั้งหมด · ประหยัด 1 call ต่อคำถาม
prompt ชัดแย้งกันเอง	สั่งทั้ง “ห้ามเขียนภาษาไทย” และ “เขียนภาษาไทยทั้งหมด” ในข้อความเดียวกัน ผลขึ้นกับว่าโมเดลแก้ความขัดแย้งทางใด — โมเดลใหญ่ทำถูก โมเดล 9B ตอบสำนวนคดีไทยเป็นภาษาอังกฤษ	ทำเป็นเทมเพลตที่ระบุภาษาครั้งเดียวในกฎข้อ 1 · ทดสอบแล้วได้ภาษาไทย 100/100
ปฏิเสธที่จะตอบ	ACKNOWLEDGE_LIMIT ลัดวงจร ไม่เรียก generation เลย — เกิด 40% ของ TRAM และ ได้ศูนย์ทุกข้อ รวมถึงข้อที่ตอบได้ชัด	ส่งสิ่งที่ขาดเข้า prompt แทน ตอบเท่าที่ข้อมูลรองรับ แล้วปิดท้ายด้วยหัวข้อขอข้อมูลเพิ่มเติม · F1 +0.149
node_label_filter	รับพารามิเตอร์แล้วไม่ส่งต่อ ผู้เรียกได้ผลลัพธ์ที่ไม่ถูกกรองโดย ไม่มีการแจ้งเตือน	ต่อพารามิเตอร์ให้ครบ · กรองฝั่งไคลเอนต์เพราะ Qdrant ต้องมี payload index
การรวมคะแนนข้าม collection	normalize แบบ min-max แยกแต่ละ collection บังคับให้อันดับหนึ่งของแต่ละฝั่งเท่ากับ 1.0 เสมอ ไม่ว่าจะเกี่ยวข้องจริงหรือไม่	เปลี่ยนเป็นรวมด้วยอันดับพร้อมน้ำหนักที่ประกาศไว้
ไม่มี timeout	ไคลเอนต์ LLM รอไม่จำกัด · 1 การเรียกค้างทำให้ทั้งชุดหยุดและไม่มีอะไรถูกเขียนลงดิสก์	timeout 120 วินาทีต่อคำขอ · 180 วินาทีต่อชุด · ทั้งตัวที่ค้างแล้วเก็บภายหลัง
พบเพิ่มเติมแต่ยังไม่แก้: gap_warning ของ PARTIAL_ANSWER เขียนลง state แล้วไม่มีใครอ่าน (แก้พร้อมข้อ 3 แล้ว) · FINAL_TOP_K = 5 ตัด context ของ LLM เหลือหนึ่งในสี่ · max_length = 512 ของ cross-encoder กำหนดตายตัวทั้งที่โมเดลรองรับ 8192		

4. ข้อค้นพบเชิงวิธีการ

4.1 ชุดทดสอบภายนอกอาจวัดคนละอย่างกับที่ระบบทำ

คลังค้นคืนของ TechniqueRAG คือ procedure example ซึ่งเป็นข้อความชนิดเดียวกับคำถาม วัดการซ้อนทับคำระหว่างคำถาม TRAM กับเอกสารเป้าหมาย ได้ค่ามัธยฐาน **0.43** เทียบกับ **0.25** ของคลังนิยามเทคนิคแบบที่ระบบนี้ใช้ และสูงกว่าใน 64% ของตัวอย่าง

สถาปัตยกรรมดังกล่าว **ใช้กับระบบนี้ไม่ได้โดยหลักการ** เพราะคำถามเป็นภาษาไทยขณะที่ฐานความรู้เป็นภาษาอังกฤษ การจับคู่คำจึงเป็นไปได้ไม่ได้ การค้นคืนแบบ dense เป็นข้อกำหนดของโจทย์ มิใช่ทางเลือกเชิงออกแบบ

4.2 การจัดอันดับข้ามภาษาได้ แต่การค้นคืนยังไม่ได้

บนเหตุการณ์ชุดเดียวกัน 100 เรื่อง ต่างกันเพียงภาษาของคำถาม				
P@1	ไทย 0.530	อังกฤษ 0.550	ต่าง 0.020	
recall	ไทย 0.507	อังกฤษ 0.633	ต่าง 0.126	
เปรียบเทียบรายตัวอย่างแบบจับคู่: 0 ต่อ 0				

ไม่มีเหตุการณ์ใดเลยที่จัดอันดับถูกในภาษาหนึ่งแต่ผิดในอีกภาษาหนึ่ง จุดอ่อนด้านภาษาไทยจึงอยู่ที่ BGE-M3 ซึ่งเป็นตัวสร้างเวกเตอร์ มิใช่ตัวจัดอันดับใหม่ เป็นตัวเลขความสามารถหลายภาษาชุดแรกของโครงการ และเป็นความสามารถที่งานคู่เทียบทั้งสามไม่มี

4.3 ข้อควรระวังเรื่องการปนเปื้อนของชุดทดสอบ

`gpt-5.6-luna` ตอบเองโดยไม่ใช้การค้นคืนได้ F1 **0.693** บน TRAM สูงกว่าแถว zero-shot ที่ตีพิมพ์อย่างมาก (GPT-4o 0.434) และสูงกว่า `qwen3.5-9b` บนโจทย์เดียวกันถึง 0.39 procedure example ของ MITRE เป็นข้อมูลสาธารณะ จึงมีความเป็นไปได้สูงว่าโมเดลรุ่นใหม่เคยเห็นระหว่างการฝึก

ข้อนี้กระทบการตีความทุกงานที่วัดผลบน TRAM ด้วยโมเดลรุ่นใหม่ ไม่ใช่เฉพาะงานนี้ และบนสำนวนคดีไทยซึ่งเขียนขึ้นเองด้วยมือ ข้อกังวลนี้ไม่เกิดขึ้น

4.4 ข้อมูลฝึกกับชุดทดสอบมาจากแหล่งเดียวกัน

กราฟของโครงการมีตัวอย่างเชิงกระบวนการ 18,383 รายการซึ่งเหมาะเป็นชุดฝึก re-ranker แต่ชุดทดสอบที่ตีพิมพ์ก็สร้างจาก MITRE procedure examples เช่นกัน ตรวจพบทับซ้อน **1,656 รายการ** (เฉพาะ TRAM คือ 228 จาก 725 หรือ 31.4% โดย 207 รายการมีป้ายเฉลยตรงกันด้วย)

การเทียบด้วยข้อความตรง ๆ ตรวจไม่พบเลย เพราะชุดทดสอบตัดชื่อผู้กระหำออกจากต้นประโยค ต้องเทียบบนข้อความที่ทำให้เป็นมาตรฐานแล้วและใช้การบรรจุอยู่ใน รายการที่ตัดออกบันทึกไว้เป็นหลักฐานตรวจสอบย้อนกลับ

5. ข้อจำกัด

- ชุดทดสอบภาษาไทยมี 100 ตัวอย่าง ความต่างต่ำกว่าราว 0.05 ควรถือเป็นสัญญาณรบกวน ผลของตัวจัดอันดับใหม่ (+0.100) อยู่เหนือเกณฑ์นั้นสองเท่า แต่ควรยืนยันซ้ำด้วยชุดที่ใหญ่ขึ้น
- วัดเฉพาะการระบุเทคนิค ยังไม่ได้วัดคุณภาพของรายงานปลายทาง ซึ่งเป็นผลผลิตจริงของระบบ
- การใช้กราฟความสัมพันธ์ยังไม่ได้ประเมินแยก — ชุดทดสอบไม่มีความสัมพันธ์ระหว่าง entity ให้ใช้เพียงพอ
- ยังไม่ได้วัด Expert และ Procedures · ยังไม่ได้รัน agent ด้วย `gpt-5.6-luna` เพื่อเทียบโมเดล
- ข้อสรุปเรื่องการปนเปื้อนเป็นการอนุมานจากคะแนน มิใช่การตรวจสอบชุดข้อมูลฝึกของโมเดลโดยตรง
- MRR เทียบกับต้นทางไม่ได้ เนื่องจากโค้ดต้นทางคำนวณหลังทำลายลำดับและให้ค่าไม่คงที่ระหว่างการรัน

6. งานที่ควรทำต่อ

#	งาน	เหตุผล	ต้นทุน
1	ปรับ prompt ให้โมเดลเลิกสกดเทคนิคได้ครบขึ้น	ช่องว่างระหว่างโมเดลอยู่ที่ recall (0.591 เทียบ 0.813) บน context ชุดเดียวกัน — โมเดลเลิกมองข้ามเทคนิคที่มีอยู่ใน context ต้องระวังการปรับ prompt ซ้ำ ๆ จนเข้ากับชุดทดสอบ 100 เรื่องนี้ ควรแก้ตามเหตุผลที่วินิจฉัยได้ครั้งเดียว มิใช่ค้นหาตัวแปรที่ให้คะแนนสูงสุด	~1 ชม. · ~\$0.10
2	ปรับปรุงตัวสร้างเวกเตอร์	ช่องว่าง recall ไทย-อังกฤษ 0.126 เป็นเพดานของทั้ง pipeline · มิโมดูล <code>embed_ab</code> อยู่แล้ว	ฟรี
3	ปรับจูน re-ranker	พิสูจน์แล้วว่ามีความคุ้มค่า (+0.100 บนโจทย์จริง) จึงมีช่องให้ปรับปรุง · ชุดข้อมูล 15,915 รายการเตรียมไว้แล้ว ประตูที่ต้องผ่าน: TRAM P@1 > 0.396 และภาษาไทยต้องไม่ต่ำกว่า 0.530	ต้องใช้ GPU คลาวด์
4	วัดคุณภาพรายงานปลายทาง	ตัวชี้วัดปัจจุบันวัดแค่รหัสเทคนิค ไม่ได้วัดสิ่งที่ผู้อ่านจริง	ต้องออกแบบเพิ่ม
5	ตรวจหา dead code ที่ตกหล่นเพิ่ม	พบรูปแบบเดิมซ้ำ 4 ครั้งใน session นี้ · จุดที่น่าสงสัยต่อ: <code>chain.py</code> ที่ไม่มีใครเรียกใช้ · <code>DUAL_QUERY_RETRIEVAL</code> · <code>translate_query()</code> · เส้นทาง <code>--ultrafast</code>	ฟรี